

ImmoVision 360

Analyse exploratoire du marché Airbnb — Périmètre Élysée

Rapport final — à destination de la Mairie de Paris
Avril 2026

Réalisé dans le cadre du projet ImmoVision 360
Données : Inside Airbnb — Paris (septembre 2025)
Pipeline : Data Lake → ETL → Data Warehouse → EDA

Sommaire

1.	Contexte et mission	p. 3
2.	Phase 1 — Constitution du Data Lake	p. 3
3.	Phase 2 — Pipeline ETL & Data Warehouse	p. 4
4.	Phase 3 — Analyse exploratoire (EDA)	p. 5
5.	Principaux résultats	p. 6
6.	Limites et perspectives	p. 7

1. Contexte et mission

La Mairie de Paris s'interroge sur l'impact des locations de courte durée sur le quartier de l'Élysée : concentration de l'offre entre quelques acteurs professionnels, déshumanisation de l'accueil, et standardisation visuelle des logements. Le projet ImmoVision 360 vise à constituer une chaîne de données complète — de la collecte brute jusqu'à l'analyse exploratoire — afin de fournir des éléments de réponse vérifiables et documentés.

Trois hypothèses majeures ont guidé l'ensemble du travail :

- A. Concentration économique** — L'offre est-elle dominée par quelques acteurs professionnels ?
- B. Déshumanisation de l'accueil** — Le lien social se brise-t-il au profit de processus automatisés ?
- C. Standardisation visuelle** — Les logements sont-ils devenus des produits financiers stériles ?

2. Phase 1 — Constitution du Data Lake

La zone Bronze du Data Lake a été constituée à partir des données publiques du portail Inside Airbnb (extraction Paris — septembre 2025). Deux sources primaires ont été ingérées : le catalogue des annonces (listings.csv) et l'historique des commentaires voyageurs (reviews.csv). Le pipeline d'ingestion a appliqué un filtre géographique strict sur le périmètre Élysée.

Résultats de l'ingestion :

Type de donnée	Fichiers attendus	Fichiers ingérés	Taux de réussite
Images (.jpg)	~2 600	2 497	~96 %
Textes (.txt)	~2 600	1 965	~76 %

La déperdition sur les images est principalement due à des liens expirés côté Airbnb (erreurs 404) et à des restrictions anti-bot. La déperdition sur les textes reflète les annonces sans aucun commentaire voyageur dans la période couverte. Ces pertes sont documentées dans le rapport de sanity check (script 03_sanity_check.py).

Architecture retenue :

Dossier	Contenu
data/raw/tabular/	listings.csv, reviews.csv (sources brutes)
data/raw/images/	2 497 fichiers [ID].jpg (320×320 px)
data/raw/texts/	1 965 fichiers [ID].txt (commentaires fusionnés)

3. Phase 2 — Pipeline ETL & Data Warehouse

La Phase 2 transforme la zone Bronze (données brutes) en une zone Silver structurée, chargée dans un Data Warehouse PostgreSQL. Le pipeline est découpé en trois scripts autonomes et idempotents : extraction, transformation et chargement.

3.1 Extraction (04_extract.py)

Sur les 70+ colonnes du fichier listings.csv, 8 ont été sélectionnées sur la base des trois hypothèses métier. Le filtre géographique sur le quartier Élysée produit un sous-ensemble de **2 625 annonces** dans le fichier filtered_elysee.csv.

3.2 Transformation (05_transform.py)

Deux nouvelles colonnes ont été créées par enrichissement IA (modèle Gemini 2.5 Flash) : le **standardization_score** issu de l'analyse visuelle des images, et le **neighborhood_impact** issu de l'analyse NLP des commentaires. Les règles de nettoyage appliquées incluent la suppression des prix nuls, l'imputation de la médiane pour les scores de notation, et l'encodage ordinal du délai de réponse hôte.

3.3 Chargement (06_load.py)

Le fichier Silver (transformed_elysee.csv, 2 625 lignes, 44 colonnes) est injecté dans PostgreSQL via SQLAlchemy. La table elysee_listings_silver est recrée à chaque exécution (mode replace — idempotence garantie).

Composition du fichier Silver :

Variable	Nature	Description
id	Identifiant	Identifiant unique de l'annonce
room_type	Nominale	Type de logement
calculated_host_listings_count	Quantitative	Nb d'annonces par hôte
availability_365	Quantitative	Jours disponibles sur l'année
host_response_rate	Quantitative	Taux de réponse hôte (%)
host_response_time	Ordinale	Délai de réponse hôte
standardization_score	Score [-1,0,1]	Profil visuel du logement (IA)
neighborhood_impact	Score [-1,0,1]	Impact social (NLP commentaires)

4. Phase 3 — Analyse exploratoire (EDA)

La Phase 3 repose sur la table `elysee_tabular`, fournie comme référence commune pour la classe. Elle contient 8 variables encodées, issues du pipeline ETL, sur lesquelles l'analyse exploratoire est conduite en trois blocs.

Bloc A — Feuille de route

Cinq questions ont été opérationnalisées avant la moindre figure, chacune rattachée à une hypothèse majeure et à des colonnes précises de la table.

#	Question	Variables	Graphique envisagé
1	Les hôtes multi-annonces ont-ils un profil hotelise ?	<code>calculated_host_listings_count</code> x <code>neighborhood_impact_score</code>	Boxplots par modalite du score
2	Repartition des profils standardises vs personnels ?	<code>standardization_score</code>	Diagramme en barres
3	La privatisation detruit-elle le lien social ?	<code>room_type_code</code> x <code>neighborhood_impact_score</code>	Barres groupees (types 1 et 2)
4	Les hotes de logements entiers sont-ils plus reactifs ?	<code>room_type_code</code> x <code>host_response_rate_num</code> x <code>host_response_time_code</code>	Boxplots + barres
5	Les multi-annonces repondent-ils plus vite ?	<code>calculated_host_listings_count</code> x <code>host_response_time_code</code>	Boxplots + nuage de points

Bloc B — Description univariee

Chaque variable de `elysee_tabular` a ete decrite individuellement : statistiques descriptives (min, mediane, max, percentiles), graphique adapte a la nature de la variable, et commentaire sur les valeurs extremes ou les proportions de -1. Le notebook `EDA.ipynb` centralise l'ensemble des analyses.

Bloc C — Croisements

Les 4 croisements planifies dans la feuille de route sont executes sur le meme `DataFrame`, chacun accompagne d'une interpretation et d'une note de prudence (liaison observee != causalite). La section Croisements du notebook documente les resultats, les limites et les facteurs communs potentiels.

5. Principaux resultats

5.1 Concentration de l'offre (Hypothese A)

Sur 2 625 annonces du perimetre Elysee, la distribution du nombre d'annonces par hote est fortement asymetrique : la mediane est de 3 annonces, mais la moyenne atteint 52, et le maximum 816 (agence Blueground). Le 3e quartile (75e percentile) se situe a 20 annonces, ce qui signifie que 25 % des hotes gerent a eux seuls une part considerable du parc.

Indicateur	Valeur
Annonces analysees	2 625
Mediane (annonces/hote)	3
Moyenne (annonces/hote)	52,2
Maximum	816 (Blueground)
75e percentile	20 annonces

5.2 Type de logements (Hypothese A + B)

Les logements entiers representent **85,6 %** de l'offre du perimetre Elysee. Les chambres privees ne constituent que 11,3 % du parc, et les chambres hotelieres 3,1 %. Cette structure confirme une offre tournee vers la location integrale, incompatible avec la presence de l'hote dans le logement.

Type de logement	Effectif	Part
Logement entier	2 247	85,6 %
Chambre privee	297	11,3 %
Chambre hoteliere	81	3,1 %
Total	2 625	100 %

5.3 Profil visuel des logements (Hypothese C)

Le standardization_score, issu de l'analyse IA des images, revele une repartition quasi equitable entre les trois categories. Sur les annonces classables (hors -1), 50,3 % sont identifiees comme personnels et 49,7 % comme industrialises.

Score	Categorie	Effectif	Part
0	Personnel	897	34,2 %
1	Industrialise	870	33,1 %
-1	Non analyse	858	32,7 %

5.4 Impact social (Hypothese B)

Le neighborhood_impact_score, issu de l'analyse NLP des commentaires, montre une repartition proche entre profils hotelises (33,9 %), voisinage naturel (32,7 %) et non analyses (33,5 %). La proportion importante de -1

(commentaires absents ou trop courts pour etre classes) constitue une limite notable pour cette variable.

Score	Categorie	Effectif	Part
1	Hotelise	889	33,9 %
0	Voisinage naturel	858	32,7 %
-1	Non analyse	878	33,5 %

6. Limites et perspectives

Limites methodologiques

Scores IA generes aleatoirement. Compte tenu des quotas de l'API Gemini (version gratuite limitee a 1 500 requetes/jour), les colonnes `standardization_score` et `neighborhood_impact` de la table Silver ont ete remplies avec des valeurs aleatoires dans $\{-1, 0, 1\}$. Les distributions observees ne refletent donc pas une analyse reelle des images et des textes, et ne doivent pas etre interpretees comme des preuves.

Absence du prix. La variable `price` n'est pas disponible dans `elysee_tabular`, ce qui empeche de relier les profils d'hotes aux dynamiques tarifaires — dimension pourtant centrale pour la Mairie.

Donnees statiques. L'analyse repose sur une extraction ponctuelle (septembre 2025). Les tendances saisonnieres et les evolutions de l'offre ne sont pas capturees.

Proportion de -1 elevee. Pres d'un tiers des annonces n'ont pu etre classees sur les scores image et texte, ce qui reduit la puissance des croisements bivaries.

Perspectives

Reevaluation IA reelle. Un traitement complet des 2 497 images et 1 965 textes avec Gemini (ou un modele local) permettrait de valider ou d'infirmar les tendances observees dans les simulations.

Enrichissement externe. L'ajout de donnees de prix (Airbnb), de bruit urbain ou de donnees cadastrales permettrait de repondre aux questions restees ouvertes sur la valeur marchande des logements.

Suivi longitudinal. Une collecte sur plusieurs periodes permettrait de mesurer l'evolution de la concentration et de la standardisation dans le temps.